

데이터 전처리 결과서

원본: D:\dev\project\SKN27-FINAL-3Team\docs\data-preprocessing-result-report-2026-07-06.md
생성일: 2026-07-06 10:59 KST

데이터 전처리 결과서

항목	내용
프로젝트	SKN27 교통분쟁 AI
문서 목적	법령, 교통 판례, 과실비율 판례, 과실비율 심의사례 전처리 및 적재 결과 정리
작성 기준	etl/, storage/schemas, 전처리 산출 JSON, PostgreSQL load report, embedding report, Git 브랜치/이슈 흐름
기준일	2026-07-06
현재 브랜치	feature/connect-fault-ratio-agent

1. 전처리 범위 요약

데이터 영역	원천/대상	처리 목적	현재 상태
법령 데이터	도로교통법, 시행령, 시행규칙, 고시/행정 기준	법령 근거 검색, 이의신청서 근거, 법률 guardrail	법령 chunk/embedding/Neo4j hint graph A/B 검증
교통 판례	교통사고 관련 판례 API 수집 결과	교통사고 맥락 판례 검색	수집, 정제, 교통사고 재분류, DB/chunk/embedding 적재 완료
과실비율 판례	교통 판례 중 과실비율 근거가 있는 판례	과실비율 RAG evidence	최종 973건 확정, DB/chunk/embedding 적재 완료
과실비율 심의사례	과실비율심의사례 PDF 472p	유사 심의사례 검색, 비율 근거 보강	226건 문서, 904 chunks, 904 embeddings 적재 완료
과실비율 인정기준	2020 비정형, 2021 PM, 2023 공식, 2025 회전교차로 등	기본과실/수정요소/Neo4j 적재 후보	전처리 보정 이력과 코드 존재, 최종 적재는 별도 확정 필요

2. Git/이슈 기반 진행 흐름

담당/이슈	관련 내용	전처리 영향
#71 법률 데이터/RAG/Neo4j	GraphRAG, PostgreSQL/Neo4j, 법령 검색	법령 chunk, embedding, hint graph 검증
#20 법률 데이터 파이프라인	법령 수집/전처리/적재	법령 RAG DB seed 및 pipeline
#69 과실비율/판례/사례 텍스트 LangGraph	판례/사례 데이터 수집, 전처리, 임베딩	교통 판례, 과실비율 판례, 심의사례 검색
#74 과실비율 RAG 프로세스	과실비율 RAG 흐름도	과실비율 판례/심의사례 evidence schema
#72 고지서 OCR/과태료·범칙금	OCR state, notice fields	고지서 데이터는 전처리 결과보다 agent 입력 schema 중심
#118 law ground search	법령 GraphRAG merge	법령 근거 검색 runtime 연결
#139 fault ratio knowledge base	과실비율 지식베이스 merge	fault ratio precedent RAG 연결
#140 text ML case search adapter	텍스트 ML 사례 검색 adapter	심의사례/판례 evidence 통합

3. 법령 데이터 전처리 결과

3.1 처리 구조

국가 법령/행정 기준 수집
-> 조문/별표/서식 단위 chunk 생성
-> normalized text/domain tags/source metadata 부여
-> embedding 생성
-> PostgreSQL pgvector 적재
-> Neo4j Hint Graph로 일상어를 법률 용어로 확장

3.2 저장 스키마

테이블	내용
law_chunks	chunk id, source, 조문/별표/서식 구분, 원문, 정규화 텍스트, 시행일/만료일, domain tags
law_embeddings	law_chunks.chunk_id 기준 embedding vector

3.3 검증 결과

항목	결과
법령 chunk 규모	99,594개
LawRelation 규모	44,761개
비교 chunk 수	68건
E5 exact-text Top-1 accuracy	0.824
OpenAI exact-text Top-1 accuracy	1.000
E5 Recall@5	1.000
OpenAI Recall@5	1.000
최종 검색 후보	OpenAI embedding + Neo4j Graph-RAG

법령 검색 A/B 테스트에서는 순수 vector only보다 Neo4j Hint Graph를 결합한 Graph-RAG가 도메인 용어 변환에 강했다. 특히 전동킥보드 -> 개인형 이동장치, 스텔스 차량 -> 등화/야간 운행처럼 사용자 표현과 법률 용어가 다른 경우 효과가 컸다.

4. 교통 판례 전처리 결과

4.1 수집 결과

항목	수치
검색 keyword 수	40
list rows seen	37,500
unique case ids	17,512
details fetched	17,512
saved candidates	17,512
errors	0

4.2 정제/중복 제거 결과

항목	수치
input rows	17,512
valid detail rows	15,716
invalid detail rows	1,796
duplicate groups	195
duplicate removed rows	196
deduped rows	15,520
quality checked rows	15,520
usable for reclassification	15,515
unusable for reclassification	5

주요 품질 플래그:

플래그	건수
numeric dense text detected	3,845
table artifact detected	1,538
many question marks remaining	889
full text too short	5
missing case category	1

4.3 교통사고 관련성 재분류

항목	수치
confirmed input rows	3,207
confirmed demoted to non-traffic	10
possible input rows	3,355
possible promoted to confirmed	365
possible to non-traffic	2,990
non-traffic input rows	8,958
final confirmed traffic rows	3,562
final non-traffic rows	11,958
final all rows	15,520

정책:

- 교통 단어만으로 승격하지 않고 사고 신호와 보조 문맥을 함께 판단한다.
- 기존 confirmed라도 사고 판례 근거가 약하면 non-traffic으로 강등한다.
- 최종 01_confirmed_traffic_cases.jsonl이 과실비율 2차 분류 입력이다.

4.4 PostgreSQL/pgvector 적재 결과

항목	결과
DB	traffic_precedent_db
case table	traffic_precedent_cases
expected rows	3,562
DB rows	3,562
count match	true
chunk strategy	structured_1500_250
chunk count	25,952
embedding model	text-embedding-3-small
embedding dim	1,536
embedding count after	25,952
too long input count	0
prompt tokens	22,230,807

chunk type:

type	count
case_overview	3,562

type	count
traffic_metadata	4,076
holding_summary	2,465
main_text	13,568
law_reference	2,281

5. 과실비율 판례 전처리 결과

5.1 2차 과실비율 분류 검증

항목	수치
fault confirmed input rows	1,151
verified fault confirmed rows	973
demoted to no fault ratio	178
possible input rows	980
possible promoted to confirmed	0
possible to no fault	980
no fault input rows	1,431
final fault ratio confirmed rows	973
final no fault ratio rows	2,589
final all rows	3,562

검증 정책:

- has_core_fault_ratio_context가 유효해야 한다.
- 손해배상/보험 문맥이 있어야 한다.
- 가중치 근거 그룹이 2개 이상이어야 한다.
- 이자율/장해율 등 과실비율이 아닌 숫자 비율 오탐을 차단한다.
- 형사/행정/산재보험 중심 판례를 confirmed에서 제외한다.

5.2 PostgreSQL/pgvector 적재 결과

항목	결과
DB	fault_ratio_precedent_db
case table	fault_ratio_precedent_cases
expected rows	973
DB rows	973
count match	true
chunk strategy	structured_1500_250
chunk count	10,833
embedding model	text-embedding-3-small
embedding dim	1,536
embedding count after	10,833
too long input count	0
prompt tokens	9,602,076

chunk type:

type	count
case_overview	973
fault_ratio_metadata	973
holding_summary	863
fault_ratio_evidence	2,895
main_text	4,341
law_reference	788

6. 과실비율 심의사례 전처리 결과

6.1 원천 및 파싱

항목	결과
원천 PDF	(최종)과실비율심의사례_(54MB).pdf
PDF pages	472
extractor	pymupdf
read page count	472
fallback errors	0
case text count	226

6.2 전처리 결과

항목	수치
document count	226
source chunk count	285
RAG chunk count	904
quality report count	226
TOC item count	226
TOC-case link count	226
valid document count	226
review required document count	0
fatal flag count	0
warning: header road context missing	116

6.3 PostgreSQL/pgvector 적재 결과

테이블	적재 건수
review_case_documents	226
review_case_source_chunks	285
review_case_chunks	904
review_case_quality_reports	226
review_case_toc_items	226
review_case_toc_case_links	226

검증 결과:

항목	결과
count validation	complete
mismatches	none
embedding model	text-embedding-3-small
embedding dim	1,536
embedding count after	904
inserted/updated embeddings	894
existing embedding before	10
too long input count	0
prompt tokens	335,563

7. 과실비율 인정기준 전처리 상태

전처리 코드와 보정 이력은 etl/fault_cases/src/fault_standard/preprocessing과 etl/fault_cases/Fault_cases_MD/인정기준/전처리 수정 계획에 정리되어 있다.

데이터	처리 방향	상태
2020 비정형 기준	PDF 텍스트를 계산 가능한 rule/chunk로 재구성	보정 이력 존재
2021 PM 대 자동차 기준	공유 해설/법규 chunk와 일반 chunk 분리	보정 이력 존재
2023 공식 인정기준	rule, base fault, variants, adjustment factors, law refs 분리	대규모 보정 이력 존재
2025 2차로형 회전교차로	lane step, entry/exit direction, role 근거 보존	보정 계획/코드 존재

현재 기준정보 전처리의 핵심 원칙:

- PDF 텍스트를 그대로 쪼개지 않고 계산/검색 가능한 의미 단위로 재구성한다.
- base_faults, variants, adjustment_factors, law_refs, reference_cases, chunks를 분리한다.
- diagram/image crop은 이번 텍스트 전처리 범위에서 제외한다.
- Neo4j 적재 시 수정요소가 아닌 문장이 수정요소로 들어가지 않도록 관계 경계를 보존한다.

8. 검색/Agent 연결 결과

Agent/검색	입력 데이터	연결 방식
law_ground_search	law_chunks, law_embeddings, Neo4j hint graph	법령 근거 검색
text_ml_case_search	review case + fault ratio precedent evidence	유사 사례, 과실비율 범위, 증거 표시
Supervisor	상담 메시지, 파일 metadata, agent outputs	worker progress와 report generation으로 연결
Report workbench	reports, agent_results, analysis_display_results	partial/final report 품질 표시

9. 품질 및 한계

영역	품질 확인	남은 한계
법령 RAG	Graph-RAG 조합에서 테스트 쿼리 5개 정답 근접률 1.00	점수 일부는 문서상 이론적 추정 포함
교통 판례	수집 오류 0, 최종 3,562건 적재 검증 완료	표/숫자 artifact 플러그가 일부 존재
과실비율 판례	precision 중심으로 973건만 확정	possible class는 전부 no_fault로 내려 recall 손실 가능
심의사례	226건 전부 valid, fatal flag 없음	header road context missing 116건
인정기준	보정 이력과 전처리 코드 존재	최종 DB/Neo4j 적재 수치 별도 확인 필요
검색 실험	pgvector, BM25/Nori, Elasticsearch, reranker 실험 구조 존재	로컬 reranker 모델은 GitHub LFS 한계로 커밋 대상 아님

10. 최종 결론

2026-07-06 기준, 프로젝트의 데이터 전처리는 단순 수집 단계가 아니라 RAG 검색과 Agent 출력에 연결 가능한 수준까지 진행됐다.

핵심 성과는 다음과 같다.

1. 교통 판례 17,512건 수집 후 15,520건 정제, 최종 교통사고 판례 3,562건을 DB에 적재했다. 2. 교통사고 판례 중 과실비율 판례 973건을 precision 중심으로 확정하고 10,833 chunks/embeddings를 생성했다.
3. 과실비율 심의사례 PDF 472페이지에서 226건 문서와 904 RAG chunks를 생성하고 DB/embedding 적재를 검증했다. 4. 법령 RAG는 OpenAI embedding + Neo4j Graph-RAG 조합이 최종 후보로 정리됐다.
5. 전처리 결과는 text_ml_case_search, law_ground_search, Supervisor, Report workbench와 연결되는 구조를 갖췄다.

후속 작업은 과실비율 인정기준의 최종 DB/Neo4j 적재 수치 확정, 법령 RAG 운영 seed 자동화, 개인정보/원문 보관 정책 확정, 검색 품질 테스트 케이스 확대다.