

수집 데이터 보고서

SK 네트워크 Family AI 27기 : 3팀
프로젝트명: 교통분쟁 AI: 과실비율·범칙금/과태료 분석 및 리포팅 서비스
작성일: 2026. 6. 22.

항목	내용
산출물 단계	데이터 수집 및 저장
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN27-FINAL-3Team
작성 팀원	3팀: hi20260204-maker, leejaegang27, ohjuheecode, techshin31, workzion2
주의	저장소 내 raw 데이터 파일이 확인되지 않은 항목은 진행 중 또는 검증 필요로 표기했다.

1. 수집 데이터 개요

데이터명	수집 대상	수집 목적	사용 예정 기능	출처/저작권
법률 원문 데이터	도로교통법, 시행령, 시행규칙, 행정 기준, 고시	과태료·범칙금 분석과 법률 근거 검색	법률 근거 검색 노드, RAG evidence	공개 법령/API, 출처 metadata 필요
과태료·범칙금 룰/매핑	위반 유형, 금액, 벌점, 예외 조건, 처분 단계	고지서 분석 결과 구조화	고지서 OCR·과태료/범칙금 분석 노드	법령 기반 내부 구조화 데이터
판례·심의·사고 사례 텍스트	판례, 과실비율심의사례, 유튜브 자막 사고 사례	사고 유형, 쟁점, 유사 사례 검색	텍스트 ML/판례·사례 검색 노드	공개 원문/자막, 사용권 검토 필요
영상·이미지 manifest	사고 사진, 차량 파손 이미지, 블랙박스/사고 영상, key frame	Vision/DL 분석과 장면 요약	영상·이미지 분석 노드	비식별 샘플만 저장, 원본 민감 파일 커밋 금지
사용자 업로드 자료	고지서, 경위서, 사고 사진, 영상, 사용자 설명	개별 사건 분석 입력	챗봇, 리포트, 이의신청서 초안	사용자 제공 자료, 개인정보 보호 대상

2. 수집 방법 및 자동화 절차

항목	내용
수집 방식	API 호출, 웹 크롤링 일부, 사용자 입력, 문서/이미지/영상 업로드, 회의/이슈/요구사항 문서 기반 데이터 범위 정리
사용 언어/라이브러리	Python requests/BeautifulSoup, OCR 도구 후보, RAG chunking/embedding 도구, Django API. 실제 라이브러리는 구현 문서 확정 후 고정
자동화 여부 및 주기	현재는 설계 단계. 법률/룰/사례/영상 manifest는 ETL 파이프라인으로 자동화 예정이며 샘플 검증 전까지 수동 검토 병행
오류 처리	OCR 실패, 필수 필드 누락, RAG 검색 실패, Agent 응답 실패, 파일 업로드 실패를 status=partial/failed와 limitations로 반환
흐름	원천 데이터 확인 -> 수집 및 전처리 -> 저장 및 색인 -> Agent evidence/limitations/next_actions 연결

3. 데이터 설명 및 구성

파일명/테이블명	필드명	데이터 타입	설명	예시
legal_documents	law_name	string	법령명	도로교통법
legal_documents	article	string	조문 번호	제32조
legal_documents	effective_date	date	시행일 또는 기준일	2026-06-22
fine_rules	violation_type	string	위반 유형	어린이보호구역 주정차 위반
fine_rules	fine_amount	integer	과태료 또는 범칙금 금액	120000
fault_cases	issue_tags	array	과실 쟁점 태그	신호, 좌회전, 선진입
media_manifest	file_type	string	이미지/영상 유형	blackbox_video
agent_results	evidence	array	근거 목록	law, precedent, vision_result
항목	내용			
전체 수집 데이터 건수	문서 기준 법령/시행령/시행규칙 총 23개 수집 완료로 기록됨. 저장소 내 raw 데이터 파일은 확인되지 않아 원본 적재 건수는 검증 필요.			
추출된 고품질 데이터 건수	법률 데이터 외 판례, 유튜브 자막, 과실비율심의사례, 영상·이미지 샘플은 진행 중 또는 검증 필요 상태로 기록.			
저장 경로	설계 기준: etl/legal, etl/fine_rules, etl/fault_cases, etl/vision_manifest, storage/rag, storage/samples. 현재 raw 데이터 저장 경로는 미확정.			
저장 포맷	CSV, JSON, DB table, RAG document/chunk 모두 후보. 구현 전 schema 확정 필요.			
인코딩	UTF-8 고정. HTML, Markdown, CSV/JSON, DB 입출력 모두 한글 깨짐 방지 기준 적용.			

4. 법적·윤리적 검토

항목	검토 내용
개인정보 포함 여부	법령/공개 사례 데이터는 미포함 가능성이 높으나 사용자 업로드 고지서/영상/사진은 개인정보 또는 민감정보 포함 가능.
포함 가능 필드	이름, 차량번호, 주소, 연락처, 위반 일시/장소, 영상/사진 속 개인 식별 정보.
비식별화	원본 민감 데이터는 Git 커밋 금지. 테스트 fixture는 비식별화 또는 샘플 대체 후 사용.
출처 및 사용권	공개 법령은 출처와 최신성 metadata를 남긴다. 판례/자막/영상은 원문 링크와 사용권 검토 필요.
라이선스/약관	진행 중. 유튜브 자막, 보험사 자료, 영상 데이터는 사용 범위 확인 필요.

5. 데이터 품질 및 정합성 관리 방안

항목	관리 방안
중복 제거 기준	source_url, law_name+article, case_id, video_id+timestamp_range, file_hash 기준 중복 제거.
정합성 검증	필수 필드 누락, 날짜 형식, 금액/벌점 타입, source_type/domain, evidence metadata를 검증.
Null 처리	필수 입력이 없으면 partial 상태와 missing_fields를 반환하고 분석보다 추가 질문을 우선한다.
표준화	HTML 제거, 광고/불필요 문구 제거, 문단 분리, chunk 분할, metadata 정규화, UTF-8 저장.

6. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2026-06-17	3팀	요구사항 정의서 v0.4 업데이트	125개 요구사항으로 재정리
2026-06-18	3팀	WBS, 역할, Agent/Supervisor 구조 정리	중간/최종 일정 기준 반영
2026-06-22	3팀	수집 데이터 보고서 PDF 작성	raw 데이터 미확인 항목은 검증 필요로 표기